

Classification de signaux physiologiques de type électrocardiogramme (ECG) par une technique d'apprentissage profond.

Niels Tilch

École d'ingénieur du Numérique
Télécom Nancy

Institut des Mines-Télécom
Villiers-lès-Nancy, France

Email : niels.tilch@telecomnancy.eu

Marie-Hélène Thomas

École d'ingénieur du Numérique
Télécom Nancy

Institut des Mines-Télécom
Villiers-lès-Nancy, France

Email: marie-helene.thomas@telecomnancy.eu

Yves Berviller

Institut Jean Lamour
Nancy, CFrance

Téléphone: +33 (0) 3 72 74 26 44
Email : yves.berviller@univ-lorraine.fr

Mots-clés : Électrocardiogramme, Réseau de neurones, Transformée en ondelettes, Pathologie Cardiaque

Abstract—Le but de ce projet est de créer un réseau de neurones et d'utiliser une technique de deep learning afin un programme ayant pour but de détecter des pathologies cardiaques à partir d'ECG. L'étude consiste à démontrer la forte utilité des réseaux de neurones dans le diagnostic des pathologies cardiaques.

I. INTRODUCTION

Pour détecter des pathologies cardiaques, l'électrocardiogramme (ECG) est l'un des outils les plus utilisés. Il consiste à enregistrer les contractions électriques du myocarde à l'origine des battements de coeur pour les retranscrire ensuite sur un graphique. Des pathologies peuvent avoir une influence sur les contractions du myocarde, ce qui se reflète ensuite sur l'ECG. La détection de ces pathologies est essentiel pour le corps afin d'avoir un premier diagnostic le plus rapidement possible et ainsi éviter les complications. L'anomalie étant parfois subtile sur cet enregistrement, un outil de diagnostic automatisé peut être d'une grande aide pour les médecins.

Or, pour pouvoir être utile et rendre service, un tel outil doit être fiable, avec une précision correcte et le moins d'erreurs possible. Le but du projet est donc de créer un programme de diagnostic d'ECG automatisé avec une fiabilité la plus grande possible.

Pour réaliser ce travail, nous avons choisi d'utiliser un réseau de neurones et une technique d'apprentissage profond. Le principe est de fournir des données, ici des ECG et leurs pathologies correspondantes, afin que l'outil apprenne à

reconnaître ces dernières si un nouvel ECG lui était montré.

Le but de ce papier est de voir la faisabilité de l'utilisation des réseaux de neurones dans le diagnostic des pathologies cardiaques. En particulier, les questions suivantes nous permettrons d'acheminement notre corpus :

- L'utilisation d'un réseau de neurones est-il fiable dans un diagnostic ?
- Existe t-il un optimum dans l'apprentissage de la classification de pathologies ?
- L'utilisation des réseaux de neurones est-elle démocratisable dans l'ensemble des centres hospitaliers ?

En s'aidant des résultats existant sur le sujet, nous avons approché le problème par la création de différents réseaux de neurones. La classification de ces réseaux de neurones est ensuite testés grâce à une banque de données et les résultats sont ensuite analysé pour trouver la meilleure approche à l'utilisation de chaque neurones (leurs points forts, leurs limites).

Cet article présente d'abord les solutions déjà existantes pour répondre à notre problématique. Puis il présentera la méthodologie utilisée pour implémenter notre outil. Enfin, les résultats obtenus seront présentés.

II. ÉTAT DE L'ART

Plusieurs techniques ont été expérimentées et/ou utilisées pour déterminer un diagnostic automatique à partir d'un ECG. Ces techniques ont évolué au cours du temps et ont varié en fonction des pathologies à détecter.

A. Modèles de Markov

Les chaînes de Markov ont été envisagées dès 1985 pour la différenciation des différents ECG. Une chaîne de Markov est constituée d'une suite de variables aléatoires telles que chaque état dépend de la probabilité de l'état précédent. Avant cela, un traitement du signal est réalisé avec plusieurs décompositions. La modélisation ne vient qu'ensuite. À l'époque, il y avait trop de détails à considérer dans le signal ECG pour obtenir une classification optimale, et les méthodes de prétraitement du signal n'étaient pas assez précises.

Les premiers modèles de classification automatique d'ECG sont apparus dans les années 1990. En 1995, les chaînes de Markov cachées sont utilisées pour de la reconnaissance automatique d'ECG. Une chaîne de Markov cachée contient deux processus, le premier étant une chaîne de Markov classique et le deuxième étant à valeurs dans R^N . Cette technique a été utilisée par le Service de Cardiologie du CHRU de Rennes. Elle a été considérée à cause de certaines propriétés de l'ECG qui augmentent les probabilités à considérer pour classer un signal. Néanmoins, le signal ECG n'étant pas stationnaire, des adaptations sont à faire pour pouvoir y appliquer la théorie des chaînes de Markov afin de faire de la reconnaissance et de la classification.

B. Réseaux de neurones

Les réseaux de neurones pour le classement de signaux ECG ont été massivement envisagés dans les années 2000. Seuls ou utilisés avec des méthodes de traitement du signal, les réseaux de neurones offrent des perspectives intéressantes. Ils ont plusieurs avantages : ils sont fiables, ils peuvent être automatisés en temps réel, ils peuvent traiter des jeux de données de grande taille, ils éliminent les erreurs, ils peuvent traiter les bruits et les nouveaux cas, et ils peuvent être implémentés selon des paramètres descriptifs. Néanmoins ils ont aussi quelques inconvénients : ils sont mal acceptés par les médecins et il faut beaucoup plus de stabilité et de fiabilité à cause du caractère sensible du domaine dans lequel ils sont utilisés.

Les résultats obtenus avec la technologie des réseaux de neurones sont souvent très bons. En août 2019, une équipe de recherche de la Mayo Clinic à Rochester dans le Minnesota aux États-Unis, composée de Zach Attia et Peter Noseworth, a utilisé un réseau de neurones convolutionnel et une technique d'apprentissage profond pour détecter des fibrillations atriales intermittentes à partir de signaux ECG. La précision globale était de 79,4, et pouvait monter jusqu'à

83,3% dans le cas d'un seul et même patient.

Une autre équipe basée à Trento, en Italie, a réitéré l'expérience et ses résultats ont été publiés en novembre 2019. La technologie a été améliorée et les résultats ont atteint une précision de 98,1%.

C. Théorie MART

MART (Multichannel Adaptive Resonance Theory) est un type de réseau de neurones dans lequel le nombre de catégories n'est pas forcément connu et dont la particularité est d'être entraîné simultanément sur plusieurs aspects des différents éléments à classer et non sur un seul comme la plupart des réseaux de neurones font. C'est une extension de ART (Adaptive Resonance Theory). En 1998, S. Barro a utilisé des réseaux de neurones MART pour classer des signaux ECG en faisant une différenciation entre des battements normaux et des battements ventriculaires : la précision était supérieure à 90%. Sajjad Moshin a également utilisé cette méthode en 2008 dans le cas d'un réseau de neurones avec apprentissage non supervisé pour détecter des points caractéristiques sur des tracés d'ECG. Dans son réseau, il y a deux canaux : un pour détecter les points Q et S sur le triangle QRS, un autre pour en détecter sur une transformée pour déterminer leur localisation exacte. Cela réduit ainsi le nombre d'erreurs par rapport à un réseau de neurones de type ART. Ainsi, le programme final contient un réseau MART hybride, ayant à la fois les fonctionnalités d'un réseau ART et celles de la programmation dynamique.

D. Théorie ARTMAP

La théorie ARTMAP (Adaptive Resonance Theory Mapping) est un réseau de neurones qui classe des données réparties de manière arbitraire dans des catégories basées sur le succès prédictif. Cette méthode a été envisagée pour détecter la Contraction Ventriculaire Prématuée (PVC), retranscrite sur l'ECG par un triangle QRS arrivant trop tôt par rapport à l'onde P. Il s'agit d'un battement anormal. Les chercheurs Ham et Han ont utilisé cette technique pour le classement d'arythmies cardiaques.

E. Démocratisation des moyens développés

Les paragraphes précédents ont montré que l'intelligence artificielle était de plus en plus envisagée pour établir des diagnostics à partir d'ECG, quelle que soit la méthode. Néanmoins, cette possibilité ne transparaisait souvent qu'à travers des recherches. Or aujourd'hui, il existe des entreprises spécialisées dans le développement de logiciels basés sur l'intelligence artificielle pour l'analyse d'ECG. Ces logiciels



Fig. 1. Schéma général de la classification d'un signal.

ont pour but d'être accessibles au corps médical et de leur faciliter la tâche.

III. MÉTHODOLOGIE

A. Analyse du problème

Dans le cadre de cette recherche, la problématique de la recherche de pathologie grâce à un signal électrocardiogramme est défini par la recherche d'une méthode de classification efficace et ayant une précision de classification pour chaque classe élevée. Les multitudes de recherches nous ont montrés plusieurs points essentiels à respecter. Tout d'abord, il est nécessaire que la méthode puisse classer un très court signal (environ deux battements de cœurs. En effet, l'utilisation doit permettre un diagnostic rapide. Avec l'apprentissage d'une centaine de signaux, la compression de l'information est nécessaire afin d'éviter un apprentissage excessivement long. Enfin, dans le cas de l'utilisation de réseaux de neurones, il est indispensable d'éviter le sur-apprentissage du réseau. L'effet du sur-apprentissage est notable dès lors que l'on fait apprendre au réseau de neurones les mêmes informations. À cet effet suit une très grande précession pour chaque classe dès que l'on évalue les signaux appris. Néanmoins, pour de nouveaux signaux, la précision est dans la majorité des cas extrêmement faible. Ainsi, la méthode de classification doit répondre à trois axes majeurs : efficacité, rapidité et être apte à la nouveauté.

B. Choix effectués et solutions proposées

Afin de juger l'efficacité des réseaux de neurones dans la classification des pathologies cardiaques, il est décidé de séparer cette classification en deux étapes : une partie pré-traitement du signal et une seconde partie étant le réseau de neurones.

La première étape consiste en un pré-traitement du signal électrocardiogramme avec l'utilisation de transformées. Une transformée a été retenue : la transformée en ondelettes continu. Cette partie de classification va nous permettre d'accomplir deux points : elle va rendre le réseau de neurone rapide en compressant l'information, et elle va nous permettre d'adapter les signaux pour les réseaux de neurones défini dans le paragraphe suivant.

Long / Short Term Memory (LSTM)




Fig. 2. Schéma d'un réseau LSTM (asimovinstitute.org)

Deep Convolutional Network (DCN)




Fig. 3. Schéma d'un réseau DCN (Deep Convolutional Network (asimovinstitute.org).

La seconde étape consiste en un réseau de neurones. Les précédentes recherches sur le sujet ont convergé vers trois solutions possibles : un réseau avec l'utilisation de couches LSTM (Long Short Term Memory) [figure 2], un deuxième avec la création d'un réseau de convolution sous le nom de CNN (Convolution Neural Network), enfin un troisième avec la création d'une DCN (Deep Convolutional neural Network) [figure 3]. Le choix d'utiliser des couches récurrentes à une importance fondamentale. En effet, avec le traitement d'un signal se déroulant dans le temps ces couches vont nous permettre de prendre en compte le passé du signal pour prendre de meilleures décisions locales. Ces couches permettent ainsi de modéliser les dépendances entre les signaux passés et présent.

Ainsi, trois différents types de classifications seront analysés et comparés afin de chercher une solution au problème donné.

C. Moyens utilisés

La conception du pré-traitement et du réseau de neurones a été sur le langage de programmation python. Pour effectuer les transformées en ondellettes, la librairie utilisée s'appelle *Scipy*. Pour la création des réseaux de neurones et de leur évaluation, la librairie *keras* de *Tensorflow* est utilisé. Les calculs d'évaluation étant élevée, un serveur de calcul était

nécessaire pour les produire. Ainsi, nous avons utilisé Google Colaborative afin de produire des résultats rapidement grâce à l'accélération GPU (carte graphique).

Afin d'évaluer notre outil, nous utilisons les signaux provenant de la base de données PhysioNet [?]. Les signaux se dénombre en 162 signaux de 65565 points chacune et étant classifiés sous 3 catégories de pathologie : [1,2,3]. Chaque signal a une fréquence d'acquisition de 104 Hz définissant ainsi chaque période cardiaque (un battement) contient au minimum 100 points d'acquisition.

D. Conception et implémentation de l'outil

La conception de l'outil se décompose en trois grandes parties : une première partie se composant de la création des signaux d'entraînement et d'évaluation traités au préalable par la transformée en ondelettes, une seconde partie portant sur la création du réseau de neurones et une troisième composée de l'évaluation et des méthodes d'analyses des résultats.

Afin d'effectuer la classification, il faut d'abord trier les signaux de la base de données. Le tri doit avoir plusieurs propriétés afin d'effectuer un entraînement acceptable pour le réseau de neurones :

- Chaque classe doit avoir le même nombre de signaux pour l'entraînement. Cette égalité forcée permet à chaque d'avoir le même "poids" lors de l'entraînement dans le réseau de neurones signifiant qu'il n'y aura pas d'apprentissage pour une classe majoritairement. Cela permet d'éviter de fausser la classification vers une seule classe.
- Maximiser le nombre d'échantillon. En élevant artificiellement le nombre d'échantillon, le réseau de neurones apprend plus sur chaque classe. Ainsi, on découpe chaque signal en plusieurs échantillons. Il est important dans ce sectionnement que celle-ci doit comprendre au moins un battement à défaut de donner de mauvais résultats lors de la classification.

Pour le tri, il est décidé ne pas respecter la première propriété lors de l'évaluation afin d'avoir un grand nombre de résultats. Lorsque le tri est effectué, nous obtenons deux matrices contenant respectivement les valeurs pour l'entraînement du réseau de neurones et les valeurs pour l'évaluation du réseau. Après cela, on applique une transformée en ondelettes permettant de compresser les signaux sans perdre d'informations sur les battements du cœur, mais aussi d'adapter partiellement le signal à la couche d'entrée des réseaux de neurones que l'on a construit : on passe d'un signal vecteur en une image à deux dimensions. Il est important

de noter que les réseaux de neurones prennent de manière préférentielle, des valeurs entre 0 et 1. Ainsi, on effectue une normalisation des valeurs. Néanmoins, cette normalisation s'accompagne par effets néfastes. En effet, le complexe QRS d'un battement ayant une amplitude deux à trois fois plus élevée que n'importe quelle autre onde, une perte d'information s'en suit par rapport aux propriétés des ondes T et S qui elle-seule peut être signe d'une pathologie si une anomalie est présente.

Après la préparation des signaux, la construction du réseau de neurones s'en suit. Afin de construire un réseau adapté à notre problème, les trois réseaux répondent aux propriétés suivantes :

- Le nombre de neurones dans chaque couche doit être à minima au-dessus du nombre de points pour une période cardiaque à l'exception de la couche de sortie. On évite ici une perte potentielle d'information sur le battement.
- Le nombre de neurones en sortie doit être égal au nombre de classes prévues. Dans le cas contraire, on observe à travers les expérimentations que la précision par classe diminue fortement.
- Afin d'éviter le phénomène de sur-apprentissage, le réseau de neurones doit contenir au moins une couche dénommée 'Dropout' permettant ainsi une perte artificielle d'information.

Les trois réseaux de neurones étudiés sont quasiment identiques à [figure [?]] à l'exception que la couche convolutive 'Conv2D' et 'MaxPooling2D' sont remplacées par une couche LSTM dans le cas de l'utilisation de LSTM et une couche 'ConvLSTM2D' dans le cas de la modélisation de la DCN. Les trois réseaux utilisent la fonction 'Sigmoid' pour la rétro-propagation lors de la phase d'entraînement.

Après la création des modèles, une évaluation est faite grâce aux signaux d'évaluation créés préalablement dans la partie de préparation.

IV. RÉSULTATS OBTENUS

Le but de cette étude est de voir l'évolution de l'apprentissage pour la classification des pathologies cardiaques. Ainsi, la troisième partie de l'outil, est dédiée à l'analyse du réseau de neurones. L'analyse se porte sur la précision de la classification au sein de chaque classe. Différents outils sont mis à notre disposition : l'observation de l'évolution de la précision et celle de sa matrice de confusion.

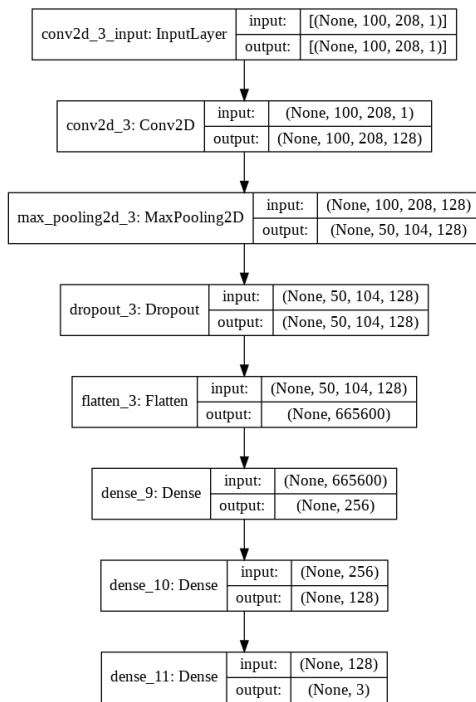


Fig. 4. Modèle du réseau utilisant les couches convolutives




Fig. 5. Résultat des précisions avec une couche LSTM




Fig. 6. Résultat des précisions avec une couche Conv2D




Fig. 7. Résultat des précisions avec une couche ConvLSTM2D

514	432	0
165	66	0
88	308	0
1	2	3

Fig. 8. Matrice de confusion après 1 epoch (couche LSTM)

483	463	0
120	111	0
250	146	0
1	2	3

Fig. 9. Matrice de confusion après 6 epochs (couche LSTM)

le cadre d'un diagnostic hospitalier[figure 7,8 et 9].

- Les réseaux construits ne sont non plus adaptés pour une classification à plus 3 classes. Cette observation est faite grâce aux matrices de confusion [figure 8 et 9].

Dans le cas de la classification de signaux, on remarque que cette classification est très sensible au sur apprentissage. En effet, la baisse notable de la précision la montre.

Néanmoins, une comparaison peut être faite : dans le cas de la classification, on remarque que les couches ConvLSTM2D sont d'autant plus performantes que les 2 autres couches.

Ainsi, les observations nous donnent un point essentiel d'amélioration possible : la recherche d'un nouveau réseaux de neurone est essentiel pour avoir un meilleur résultat au niveau de la précision de la classification par classe.

Plusieurs points ont été observés

- Les résultats de l'évaluation sur long terme nous montre que les modèles créés pour l'apprentissage profond n'est pas adapté. En effet, on remarque une précision d'environ 0.62 pour son optimum ce qui n'est pas satisfaisant dans

V. CONCLUSION

Nous avons pour but d'utiliser une technique d'apprentissage profond pour créer un programme capable de reconnaître une pathologie cardiaque à partir d'un signal de type électrocardiogramme (ECG), et ce en quatre mois. Trois classes d'ECG devaient être reconnues : le rythme sinusal normal, l'arythmie cardiaque et l'insuffisance cardiaque congestive.

Le projet s'est divisé en plusieurs étapes. Tout d'abord, il nous a fallu faire des recherches sur l'anatomie du coeur et le principe de l'ECG afin de mieux comprendre l'intérêt de notre sujet ainsi que les données à manipuler.

Ensuite, nous devions déterminer un type de transformée du signal pour l'appliquer sur les signaux ECG que nous avons avant leur classement par un réseau de neurones. Nous avons testé la transformée de Fourier et la transformée en ondelettes, le but étant de déterminer lequel permettait le mieux de différencier les ECG en fonction des pathologies associées. Notre choix s'est porté sur la transformée en ondelettes, majoritairement utilisée pour des travaux du même type.

Enfin, nous devions tester plusieurs types de réseaux de neurones pour obtenir les résultats les plus satisfaisants possibles, avec ou sans prétraitement du signal. Les deux réseaux de neurones que nous avons retenus étaient le Long / Short Term Memory (LSTM) et le Deep Convolutional Network. Malheureusement, aucun des deux n'a donné de résultats assez satisfaisants.

Nous avons traversé plusieurs difficultés. Au début du projet, nous avons du mal à nous projeter dans le travail à effectuer en raison d'une méconnaissance des réseaux de neurones lors de cette période. Nous avons également rencontré des difficultés d'implémentation. Néanmoins nous avons pu surmonter ces soucis.

Un réseau de neurones peut être fiable lors d'un diagnostic d'ECG, mais il est difficile d'en réaliser un qui est satisfaisant. Certaines équipes de recherche ont réussi à en mettre en place et avec des résultats qui s'améliorent au fil du temps, mais cela demande du temps et des innovations techniques.

Il existe un optimum dans l'apprentissage de la classification de pathologies avec des résultats justes pouvant atteindre une proportion élevée, mais la précision n'est pas toujours acceptable pour qu'un réseau de neurones puisse être utilisé

à un usage courant.

Leur utilisation pourra tout de même être démocratisable à l'avenir. Les techniques de diagnostic automatique pourraient être d'une grande aide auprès d'une équipe médicale, la technologie s'améliore, et des entreprises visant à cette démocratisation commencent à voir le jour. En revanche, la technologie doit encore être améliorée et doit surtout gagner la confiance de la communauté médicale.

REMERCIEMENTS

Nous aimerions tout d'abord remercier Monsieur Yves Berviller, notre encadrant qui a été à l'écoute pendant toute la durée du projet, qui nous a écoutés avec attention et qui a su nous conseiller et nous guider lorsque nous en avons besoin. Nous voudrions aussi remercier nos professeurs qui nous ont apporté des connaissances nécessaires à la réalisation de ce projet, quelle qu'en soit la sorte : réseaux de neurones, traitement du signal, création d'un document LaTeX, mais aussi gestion de projet, communication, rédaction d'un rapport ou d'un article, et savoir-être. Nous remercions TELECOM Nancy pour nous avoir donné ce projet, nous permettant ainsi de nous donner un aperçu du domaine de la recherche et plus globalement de l'étendue des compétences pouvant être détenues à la sortie de nos études.

Enfin, nous remercions nos camarades de TELECOM Nancy, que ce soit dans notre promotion ou dans les autres, pour nous avoir soutenus et encouragés dans des moments parfois difficiles et pour avoir été à notre écoute lorsque nous en avons besoin.

REFERENCES

- [1] Peter Charles Doeschunk, *A Markov Chain Approach To Electrocardiogram Modeling And Analysis*, 3rd ed. Massachusetts Institute of Technology, 1985.
- [2] Selwa Rafi, *Chaînes de Markov cachées et séparation non supervisée de sources*, 3rd ed. National des Télécommunications, 2012.
- [3] L. Thoraval, G. Carraut, J.M. Schleich, *Synthèse et reconnaissance automatique d'ECG par modèles markoviens cachés*, 3rd ed. CHRU de Rennes, 1995.
- [4] Mohamed Lamine TALBI, *ANALYSE ET TRAITEMENT DU SIGNAL ÉLECTROCARDIOGRAPHIQUE (ECG)*, 3rd ed. UNIVERSITÉ MENTOURI DE CONSTANTINE FACULTÉ DES SCIENCES DE L'INGÉNIEUR DÉPARTEMENT D'ÉLECTRONIQUE, 2011.
- [5] Mr. Amar HODNI, *ANALYSE DU SIGNAL ECG PAR RESEAUX DE NEURONES RECURRENTS*, 3rd ed. Université Mentouri, Constantine, 2009.
- [6] Sajjad Mohsin, *Unsupervised Learning based Feature Points Detection in ECG*, 3rd ed. COMSATS Institute of Information Technology.